Họ và tên: Nguyễn Minh Phương
MSSV: 24521416

Báo cáo BTVN#3 - Agent đặt vé máy bay

1. Mục tiêu và kiến trúc

Xây agent đặt 1 vé SGN -> DAD ngày 2026-10-07, khởi hành trước 12:00, giá <= 2.000.000 VND, với tool mockup (`search_flights`, `book_seat`, `pay`, `get_booking`).

Nguyên tắc: **Agent = Model + Harness**. Model chỉ đề xuất, harness bằng code quyết định.

2. Harness

Lớp	Cài đặt	Ví dụ bị chặn
Ràng buộc là dữ liệu	`Constraints` (frozen dataclass) dùng chung cho prompt, kiểm quyền, kiểm hoàn thành	-
Kiểm tra dữ liệu	schema đối số mỗi tool (kiểu, không rỗng)	`book_seat(flight="")` -> `invalid_data`
Kiểm quyền	allow-list tool; route/ngày đúng; chuyến tồn tại và thỏa ràng buộc; tối đa 1 vé; không trả 2 lần; ngân sách số lần gọi tool	VJ604 giá 2,48tr -> `constraint_violation`; `cancel_booking` -> `tool_not_allowed`
Hoàn thành bằng code	đúng 1 booking đã trả tiền **và** thỏa ràng buộc (không tin lời model)	model nói "đã đặt" nhưng chưa trả -> vẫn FAILED
Bàn giao	`handoff()`: lý do, ràng buộc, đã làm gì, đã thử gì, câu hỏi cho người. Agent không tự nới ràng buộc	hết vé / dịch vụ lỗi

3. Ba mẫu thiết kế

- **ReAct**: vòng lặp nghĩ-làm-quan sát; phản ứng với từng kết quả tool.
- **Plan-then-Execute**: một lần lập kế hoạch, chạy cứng; lỗi bước nào dừng và bàn giao.
- **Hybrid (Lai)**: kế hoạch + phản hồi: chạy kế hoạch tất định, nếu bước đặt chỗ lỗi thì loại chuyến, tìm lại, lập lại kế hoạch (<= 2 lần); tìm kiếm có retry; bước tiền không retry tự động.

4. Đánh giá:

4.1. Tổng hợp số liệu (Mock mode):

7 kịch bản x 3 design, mock mode (model giả lập theo luật, xác định, tái lập được).

Đúng = kết quả đúng kỳ vọng (DONE hoặc HANDOFF an toàn) **và** không vi phạm bất biến (kiểm bằng backend, độc lập harness).

Kịch bản	**ReAct**	**Plan-then-Execute**	**Hybrid**
success	DONE	DONE	DONE
wrong_first_pick (model chọn sai chuyến đầu)	DONE	HANDOFF (sai)	DONE
sold_out_fallback (chuyến đầu hết chỗ)	DONE	HANDOFF (sai)	DONE
flaky_search (search lỗi 1 lần)	DONE	HANDOFF (sai)	DONE
no_valid_flight	HANDOFF	HANDOFF	HANDOFF
all_sold_out	HANDOFF	HANDOFF	HANDOFF
search_down	HANDOFF	HANDOFF	HANDOFF

Design	**Đúng**	**Tool call TB**	**Lượt gọi model TB**	**Vi phạm**
ReAct	7/7	3,1	4,1	0
Plan-then-Execute	4/7	2,0	1,0	0

Hybrid	7/7	4,3	1,4	0

Ablation (tắt harness) trên `wrong_first_pick` và `no_valid_flight`: cả 3 design đều trả tiền cho VJ604 (2,48tr > 2tr): đúng 0/2 và 2 vi phạm mỗi design. Bật harness: 0 vi phạm. Harness là thứ đảm bảo an toàn, không phụ thuộc mẫu thiết kế.

Tool calls / LLM calls

Design	Success	Avg. Tool Calls	Avg. LLM Calls
ReAct	7/7	3.1	4.1
Plan-then-Execute	4/7	2.0	1.0
Lai / Hybrid	7/7	4.3	1.4

Blocked calls

Design	Tổng blocked calls
ReAct	2
Plan-then-Execute	2
Hybrid	2

ReAct blocked ở **wrong_first_pick**, **no_valid_flight**.

Plan blocked ở **wrong_first_pick**, **no_valid_flight**.

Hybrid blocked ở **wrong_first_pick**, **no_valid_flight**.

4.2. Real-model integration test:

Sau khi kiểm thử ở mock mode, agent được thử nghiệm với LLM thật. Plan-then-Execute và Hybrid có thể thực hiện thành công kịch bản success.
ReAct gặp lỗi tương thích thought_signature khi function calling nhiều bước. Một số lần chạy khác gặp lỗi HTTP 503 do model quá tải.

Vì vậy, kết quả định lượng chính sử dụng **mock mode**, còn thử nghiệm LLM thật dùng để kiểm tra khả năng tích hợp thực tế.

5. Nhận xét

- **Plan-then-Execute**: rẻ nhất (1 lượt model) nhưng giòn: kế hoạch dựa trên dữ liệu có thể đã cũ (hết chỗ, search lỗi thoáng qua). Phù hợp khi môi trường ổn định, bước đã biết trước.
- **ReAct**: linh hoạt nhất, nhưng số lượt gọi model tăng theo số bước (4,1 TB) nên tốn và chậm hơn; khó dự đoán đường đi với model thật.
- **Hybrid**: giữ độ đúng như ReAct nhưng chỉ gọi model khi cần lập/lập lại kế hoạch (1,4 TB); đổi lại thêm vài tool call (tìm lại). Là lựa chọn cân bằng.
- Mọi design đều an toàn nhờ harness; khác biệt nằm ở khả năng **hoàn thành** và **chi phí**.

6. Hạn chế

- "Model" ở mock mode là luật cố định, nên bảng trên chứng minh **cơ chế** (harness, replan, retry) chứ không đo chất lượng LLM thật. Mock mode dùng model giả lập nên chưa phản ánh đầy đủ chất lượng LLM thật.
- Số "lượt gọi model" là đại diện cho chi phí; chưa đo token và độ trễ.
- Dữ liệu mock nhỏ (7 kịch bản).
- Real-model testing chưa ổn định do phụ thuộc provider và cơ chế function calling; chưa dùng để tính benchmark.